Audion Address Processor

English · Руководство · ОКТМО · Справочник · Установка

Содержание

- Зачем это сделано
- Как решается
- Что умеет
- Принципы
- Документация
- Техническая часть
  - Источники
  - Настройки
  - Диагностика

Работа с российскими адресными данными: сопоставление таблиц по адресу, сборка чистых адресов из разнородных источников, эталонный справочник, коды территорий, сортировка и разбор на составляющие.

Зачем это сделано

Адрес — худшее, по чему можно сводить таблицы, и одновременно единственное, что есть в большинстве муниципальных данных.

Один и тот же дом в двух выгрузках выглядит так: `г. Сургут, ул. Ленина, д. 12` и `Сургут, Ленина 12`. Или `пр-т Мира, 5к1` и `проспект Мира, дом 5, корпус 1`. Или в одной таблице адрес в одном столбце, а в другой разложен на четыре.

Сопоставление по точному совпадению даст десять процентов попаданий. Сравнение на глазок — час работы на сотню строк и ошибки, которые никто не заметит.

Как решается

Пять этапов сопоставления с уточняющими проходами, от строгого к мягкому. Строка ищет пару сначала точным совпадением, затем по разобранным составляющим, затем по приведённому к общему виду отпечатку, и лишь потом приблизительно.

Порядок не случаен: **строгое совпадение никогда не проигрывает приблизительному**. Если дом нашёлся точно, мягкий поиск уже не рассматривается — иначе похожая строка из соседнего района перебьёт верную. Найденная пара сразу изымается из пула кандидатов, поэтому один и тот же дом не может быть выдан дважды.

Полный разбор проходов — в Справочнике.

Что умеет

Выравнивать таблицы по эталонному адресному столбцу — и переносить рядом стоящие столбцы вместе с адресами, чтобы данные не разъехались.

Собирать чистые адреса из чего угодно: таблиц, документов Word и ODT, текста, CSV, разметки и PDF с текстовым слоем.

Вести эталонный справочник со слотами: индекс, муниципалитет, населённый пункт, улица, дом, код территории и технические ключи.

Сортировать и разбирать справочник по выбранной иерархии слотов — от региона к дому или в любом другом порядке.

Переносить колонки между книгами по адресу дома — не копированием строк, а через Excel, с сохранением формул, оформления, листов и порядка строк основной книги.

Опираться на реестр ОКТМО Росстата. Регион и муниципалитет выбираются из официального реестра, названия населённых пунктов раскрываются в падежные формы и сужают поиск до нужной территории. Реестр скачивается кнопкой прямо из окна — см. ОКТМО.

Читать кривые шапки. Двухуровневый заголовок собирается целиком: строка без значений-данных, стоящая под объединённым родительским заголовком, считается подзаголовком независимо от того, какими словами он написан. Столбец «Проектная мощность, мест» над «по корпусам» становится «Проектная мощность, мест по корпусам», а не безымянным `column_5`, и сама строка подзаголовков не уезжает в данные.

Принципы

Исходники не меняются. Результат всегда пишется в отдельную папку. Что пришло — то и осталось.

Столбцы задаются как в Excel. `A`, `B`, `AC` — теми же буквами, что видны в заголовке таблицы, а не порядковыми номерами.

Настройки можно не править руками. Всё лежит в файле настроек, но столбцы безопасно задаются прямо в окне.

Каждый прогон оставляет отчёт. Рядом с результатом в `report/` появляется JSON: что нашлось, чем нашлось, что осталось без пары.

Окно и командная строка делают одно и то же. Любая операция запускается и без окна — командой `address_cli.cmd`, с теми же умолчаниями полей, — см. Справочник.

Таблица на выходе читаема. Ширина столбцов подбирается по содержимому, длинный текст переносится, высота строк растёт. Мелочь, но без неё выгрузку приходится доводить руками каждый раз.

Документация

Документ	О чём
Руководство пользователя	Окно, рабочие папки, все команды по шагам
ОКТМО и ключи проекта	Реестр Росстата, скачивание, обновление, кэш, ключи, пины
Технический справочник	Слоты, проходы сопоставления, настройки, отчёты
Установка и запуск	Portable-окружение, сборка окна, обслуживание
Карта файлов проекта	Где что лежит в исходниках

Техническая часть

Источники

`.xlsx`, `.docx`, `.odt`, `.txt`, `.csv`, `.md` и `.pdf` с текстовым слоем. Старые `.doc` и `.xls` конвертируются отдельной командой.

Текст из PDF читает библиотека PyMuPDF, а она распространяется под GNU AGPL 3.0. Собственный код программы остаётся под Apache 2.0, но сборка целиком — программа вместе с PyMuPDF — идёт на условиях GNU AGPL 3.0; подробнее — в файле `NOTICE`.

Настройки

`config/project.yaml`. В окне доступны безопасные поля для столбцов — файл править не обязательно.

Диагностика

Отдельный разбор работы обработчика и безопасная очистка полностью пустых строк — без риска зацепить строки с данными в одном столбце.