Руководство пользователя

English · Описание · OKTMO · Справочник

Содержание

- 1. Запуск
- 2. Окно и рабочие папки
- 3. Как устроена карточка операции
- 4. Операции
- 5. Обслуживание
- 6. Порядок работы

Программа работает окном: операции выбираются мышью, столбцы задаются буквами Excel, результат уходит в отдельную папку. Править файлы настроек для обычной работы не требуется. Те же операции запускаются и без окна — консольной командой (см. Справочник).

1. Запуск

`Start.exe` в корне проекта открывает окно программы. Если окно уже открыто, второй запуск выводит его вперёд, а не открывает второе. При первом запуске окно русское; кнопки **RU** и **EN** справа в заголовке переключают язык на лету, выбор запоминается.

Если окно не появилось или в журнале написано, что нет Python проекта, смотрите Установку.

2. Окно и рабочие папки

Окно состоит из трёх частей.

Заголовок. Название, версия и значки машины: дата снимка реестра OKTMO и наличие Excel и Word (зелёная точка — на месте; Excel нужен переносу колонок и сравнению таблиц, Word —

конвертации старых `.doc`). Справа: **СЕРВИС** (открыть папки программы, очистить `input` и `output`), **Aa** (размер шрифта: обычный, крупнее, мельче), **RU / EN**, смена темы и **ABOUT** (версия, папки, автор, лицензия).

Разделы. Под заголовком пять больших кнопок: ИСТОЧНИКИ, СБОР, ЭТАЛОН, СОПОСТАВЛЕНИЕ, ОКТМО. Если в разделе несколько операций, под ними стоит вторая строка — вкладки операций.

Две колонки. Слева — карточка выбранной операции. Справа — рабочая зона (ИСТОЧНИК и НАЗНАЧЕНИЕ), РЕЗУЛЬТАТ и ЖУРНАЛ. Внизу — строка состояния: во время работы в ней ход, время и кнопка **СТОП**.

Рабочие папки

Проект работает с шестью управляемыми папками:

Папка	Что в ней
`input`	Исходные файлы
`output`	Результаты
`report`	JSON-отчёты прогонов
`logs`	Журналы операций
`workspace`	Промежуточные файлы
`release`	Архивы результатов

ИСТОЧНИК — откуда операции берут таблицы и документы: папка или один файл. **НАЗНАЧЕНИЕ** — куда они кладут результат. При запуске это всегда `input` и `output` проекта: прошлый выбор не вспоминается. Путь можно выбрать кнопкой папки (у источника ещё и кнопкой файла), вписать в строку, выбрать из истории или бросить файл либо папку прямо в окно. Путь можно закрепить булавкой — закреплённые идут в списке первыми — и открыть в проводнике. История путей хранится в `config/path_history.json`. Пока идёт операция, пути не меняются.

Кнопки под путями:

Кнопка	Действие
СБРОСИТЬ	Вернуть оба пути к `input` и `output`; закрепления остаются

Кнопка	Действие
СПИСОК	Назвать файлы источника в журнале: по алфавиту, с номерами
ПРОВЕРИТЬ	Операция «Проверить исходники»: перечислить поддерживаемые таблицы
ОЧИСТИТЬ	Удалить содержимое источника и назначения; сами папки остаются. Окно спрашивает и называет оба пути, удалённое уходит в Корзину

Пробелы и кириллица в путях поддерживаются.

Проверяйте список перед запуском. Команда работает с подготовленным набором файлов, а не с последним, который вы открывали в проводнике.

---

3. Как устроена карточка операции

Каждая операция открывается одинаково.

- Сверху — название, строка «для чего» и справа залитая кнопка **ЗАПУСТИТЬ** (Ctrl+Enter). Объяснения полей и кнопок — в подсказках: они появляются, если задержать указатель.
- **Поля** сгруппированы рамками по смыслу: Файлы, Листы, Колонки, Строки, Опции, Режим. Рамки встают в одну, две или три колонки по ширине окна. У короткого поля подпись слева; выбор из нескольких вариантов и наборы флажков подписаны сверху. Маленькая оранжевая точка у поля — значение отличается от умолчания.
- **Дополнительно** — поля, которые обычно не нужны: пути к папкам данных, ручные переопределения.
- **ЖУРНАЛ** справа — ход операции в реальном времени; длинная стадия показывает одну живую строку, а не сотню одинаковых. Вкладки LOGS, REPORT и CONFIG открывают папки, кнопки справа копируют журнал, очищают панель (файлы в `logs` остаются) и разворачивают журнал на всю колонку.
- **РЕЗУЛЬТАТ** — итог последней операции: что она нашла и сколько. Кнопки: **ОТЧЁТ** (сводка отчёта), **ПАПКА** (папка, куда легли книги), **В ИСТОЧНИК** (сделать эту папку источником следующей операции); ниже — **ОЧИСТИТЬ ПУСТЫЕ СТРОКИ** и **УПАКОВАТЬ РЕЗУЛЬТАТЫ** (см. Обслуживание).

Одновременно выполняется одна операция. Пока идёт прогон, другая не запустится. **СТОП** просит операцию закончить в ближайшей безопасной точке: готовые книги остаются, свои Excel

и Word операции закрываются. Закрыть окно во время работы можно — оно спросит и закроется, когда операция остановится.

Операции, которые изменяют управляемую рабочую область, спрашивают подтверждение и показывают, что именно будет затронуто.

Как задаются колонки

Буквами, как в Excel: `B`, `C,D`, `AC`. Порядковые номера тоже принимаются. Несколько колонок — через запятую.

Пустое поле почти всегда означает автоматический режим, а не ошибку.

Там, где есть поле «заголовок», колонку можно выбрать по названию из первой строки книги. Явно заданная буква имеет приоритет над заголовком.

---

4. Операции

Раздел	Вкладки	Где описано
ИСТОЧНИКИ	КОНВЕРТАЦИЯ DOC/XLS · ПРОВЕРКА ИСХОДНИКОВ · ДИАГНОСТИКА ПАРСЕРА	4.8, 4.9
СБОР	—	4.2
ЭТАЛОН	НОРМАЛИЗАЦИЯ · ОБРАБОТКА	4.4, 4.5
СОПОСТАВЛЕНИЕ	АДРЕСА · ДВЕ ТАБЛИЦЫ · ПЕРЕНОС КОЛОНОК	4.3, 4.6, 4.7
ОКТМО	КЛЮЧИ И ОБЛАСТЬ · ОБНОВИТЬ РОССТАТ	4.1

4.1. ОКТМО / ключи проекта

Реестр территорий, ключи поиска и пины. Реестр **скачивается операцией** ОБНОВИТЬ РОССТАТ и обновляется ею же, кэш перестраивается сразу.

Это отдельный документ: ОКТМО и ключи проекта.

4.2. Сбор адресов

Рекурсивно собирает адресоподобные значения из XLSX, DOCX, ODT, TXT, CSV, MD и PDF с текстовым слоем, объединяет свидетельства по слотам, отбрасывает неполные строки и пишет книгу адресов.

Применяется, когда сначала нужна инвентаризация, а не сопоставление.

Действие

- *Создать новую таблицу* — собрать всё с нуля.
- *Добавить адреса к готовой* — дописать собранное в существующую книгу.

Источники. «Папка источников» — необязательная папка для рекурсивного обхода; пусто означает всю папку исходников. «Папка адресной таблицы» — где лежит готовая книга адресов.

Колонки. «Адресные колонки» ограничивают разбор конкретными колонками XLSX; пусто — сканируются все ячейки и все поддерживаемые файлы. Для режима дописывания задаются «Колонка собранного адреса» и «Целевая адресная колонка».

Слоты. Одно поле — **Линейка адреса**. Вверху она показывает, как запишется адрес (образец, менять его нельзя). Под образцом — по фишке на каждый слот иерархии: галочка включает слот, число справа — его место среди включённых, а саму фишку можно перетащить, чтобы поменять порядок. Ниже — «Технические ключи» (код ОКТМО, основание дома и другие): у них только галочки. Кнопка со стрелкой возвращает включённые слоты и порядок к умолчаниям манифеста. Полный список слотов — в Справочнике.

Опции

Опция	Что делает
Пропускать микрорайон при наличии улицы	Колонка микрорайона остаётся, но в собранную строку не входит
Чистая новая книга	Компактная книга только с адресной колонкой вместо полной
Схлопывать дубли	Объединить кандидатов с одинаковым адресным ключом и выбрать лучшие значения слотов голосованием
Чистить неполные адреса	Убрать улицу без дома, дом без улицы, адрес из одного региона и табличный мусор
Писать лист отбраковки	Отбракованные кандидаты уходят на отдельный лист для аудита

Опция	Что делает
Включить ключи ОКТМО	Определять территорию по реестру и ключам проекта

Эталон для сверки. Необязательная книга с контрольной адресной колонкой. Используется только для оценки качества сбора и пишет `report/address_collection_benchmark.json`.

Результат. Книга `AddressCollection_*.xlsx` в папке результата и отчёт `report/address_collection_summary.json`.

После сбора проверьте: пустые значения, дубли, ячейки с несколькими адресами и строки, где есть организация, но нет адреса.

4.3. Сопоставление адресов

Основной режим. Сравнивает адресные колонки с эталонной, переставляет строки так, чтобы адреса встали напротив своих пар, и переносит связанные колонки вместе с ними.

Колонки. «Колонка GT» — эталонная адресная колонка (пусто = автоопределение). «Адресные колонки» — что сопоставлять; пусто означает взять до пяти колонок справа от эталона.

Режим выравнивания

- *Быстрое выравнивание* — сопоставление без дополнительной обработки.
- *Выравнивание + нормализация* — тот же поиск, затем очистка адресных колонок результата.

Связанные колонки. Значения из связанных колонок едут вместе с найденным адресом, чтобы данные не разъехались.

Режим	Поведение
Авто	Прежняя автоматика
Нет	Чистое сопоставление адресных колонок
Слева	Колонки левее каждого адреса
Справа	Колонки правее каждого адреса
Всё между GT и адресом	Одна дальняя колонка тащит за собой весь блок между эталоном и собой

Последний режим отвечает на частый случай: эталон в `A`, адрес в `AC`, и всё `B:AB` должно переехать вместе с `AC`.

Поле «Сателлитные колонки» задаёт связи явно, если автоматика не подходит.

Выравнивание и нормализация. «Нормализовать до сопоставления» — более медленный режим с общим нормализатором. «Собрать до сопоставления» строит чистых кандидатов из выбранных колонок перед поиском; «Весь документ» расширяет сбор на всю книгу. «Город по умолчанию» задаёт название города, которое вычищается из ключей при нормализованном сопоставлении.

Результат. Книга результата в папке вывода и `report/address_alignment_summary.json`. В журнале — сводка по каждой колонке: сколько строк нашлось каждым проходом, сколько точных, сколько мягких, сколько осталось без пары.

Как читать сводку. Высокий процент мягких попаданий — повод посмотреть глазами. Точное совпадение доказательно, приблизительное — гипотеза.

4.4. Нормализация эталона

Создаёт эталонный справочник адресов из источников или приводит существующий к текущему набору слотов.

Действие

- *Сгенерировать* — новый справочник из источников.
- *Обновить* — дополнить существующий.
- *Чистка слотов* — перестроить устаревшие слот-колонки.

Опции. «Схлопывать старые дубли» объединяет записи с одинаковым ключом слотов. «Перестроить старые слоты» удаляет устаревшие слот-колонки и пишет только текущий набор. «Чистая новая книга» даёт компактный результат.

Результат. Книга `AddressReference_*.xlsx` и `report/reference_normalization_summary.json`.

Нормализация детерминирована: пробелы, пунктуация, регистр, сокращения и выделение составляющих обрабатываются одинаково от прогона к прогону. Исходное значение адреса сохраняется в результате.

Нормализованный ключ помогает поиску, но не заменяет доказательную исходную строку.

4.5. Обработка эталона

Сортирует эталонную адресную колонку по слотам или раскладывает её на отдельные слот-колонки.

Действие: *Сортировать*, *Разложить*, *Сортировать + разложить*.

Порядок слотов здесь определяет иерархию сортировки: какой слот доминирует первым. Регион → муниципалитет → населённый пункт → улица → дом, или любой другой порядок.

Заголовки слот-колонок: *Полные* (`Postal_Index`, `Municipality`) или *Короткие* (`Index`, `Municipality`).

Удалить исходную адресную колонку — при разложении слот-колонки вставляются, а исходная убирается.

Результат. Обработанная книга и `report/reference_processing_summary.json`.

4.6. Сравнить две таблицы

Берёт любые две книги, собирает адрес из указанных колонок каждой, нормализует, сопоставляет дома и создаёт **отдельную** книгу сравнения. Обе исходные книги остаются нетронутыми.

Поля. Таблица A и Таблица B, листы, адресные колонки каждой, первая строка данных каждой. Адресные колонки B могут стоять на других позициях, чем в A.

Сортировать адреса внутри групп. Выключено — сначала идут сопоставленные строки в порядке A, затем «только A» и «только B». Включено — внутри каждой группы строки отсортированы по адресу.

Результат. Книга сравнения со статусной колонкой и цветовой заливкой:

Статус	Цвет	Значение
сопоставлено	зелёный	Ровно одна пара
сопоставлено: N строк B	жёлтый	Несколько кандидатов, нужен просмотр
только A	оттенок A	Пары нет
только B	оттенок B	Пары нет

Плюс `report/table_comparison_summary.json`.

4.7. Перенести колонки по адресу

Находит одинаковые дома в двух книгах и переносит выбранные колонки из источника в соответствующие строки основной книги.

Простое копирование строк здесь не годится: порядок строк основной книги, её формулы, оформление и листы должны остаться на месте. Поэтому перенос идёт через Excel, а основная книга сначала копируется в папку результата и правится уже копия.

Поля. Основная книга и книга-источник, листы (в источнике можно отметить несколько), адресные колонки обеих, «Поля для переноса» — что именно переносить, первые строки данных и строка заголовка результата.

Результат. Копия основной книги с добавленными колонками, статусной колонкой и листом аудита `AUDIT_ADDRESS_JOIN`. Статусы: `сопоставлено`, `сопоставлено: N записи`, `не найдено`. Отчёт — `report/safe_table_join_summary.json`.

Проверьте, что один адрес не разрешился в несколько несовместимых строк: именно это показывает статус с числом.

4.8. Конвертация DOC/XLS

Превращает старые `.doc` и `.xls` в исходниках в `.docx` и `.xlsx`.

Перезаписывать существующие — выключено, существующие `.docx`/`.xlsx` сохраняются. Дополнительно удаляются одноимённые PDF/TXT/CSV/MD дубликаты, оставшиеся от прежних конвертаций.

Отчёт — `report/legacy_office_conversion_report.json`.

4.9. Диагностика

Две подкоманды.

Диагностика парсера извлекает разобранные составляющие адреса из исходников и показывает их как есть. Это способ понять, почему конкретный адрес не нашёл пару: видно, что программа сочла улицей, что домом, а что территорией.

Проверить исходники перечисляет поддерживаемые таблицы в папке исходников и попутно убирает временные файлы Office.

---

5. Обслуживание

Кнопка	Что делает
ОЧИСТИТЬ (рабочая зона)	Удалить содержимое выбранных источника и назначения; сами папки остаются, удалённое уходит в Корзину
СЕРВИС → «Очистить input и output программы (операция)»	Операция: удалить содержимое управляемых `input` и `output` проекта, сами папки остаются
ОЧИСТИТЬ ПУСТЫЕ СТРОКИ (панель результата)	Создать копии результатов без строк, пустых по всем колонкам
УПАКОВАТЬ РЕЗУЛЬТАТЫ (панель результата)	Собрать `release/address_aligner_output.zip` из папки результата

Очистка пустых строк убирает только строки, пустые целиком. Строка с данными в одной-единственной колонке считается непустой и остаётся.

Очистка папок ограничена управляемой рабочей областью: `cleanup_managed_workspace_only` и `never_delete_original_inputs` в `config/project.yaml` не дают ей выйти за пределы проекта и удалить оригиналы.

---

6. Порядок работы

Типовой прогон:

1. **Подготовьте реестр ОКТМО**, если работаете с территориальным контекстом — один раз операцией ОБНОВИТЬ РОССТАТ, дальше по мере выхода новых срезов.
2. **Наберите ключи** региона или муниципалитета в разделе ОКТМО.
3. **Сложите исходники**, проверьте список.
4. **Прогоните на маленьком контролируемом наборе** — десяток строк, где ответ известен заранее.
5. **Запустите полный прогон.**
6. **Прочитайте отчёт.** Прогон не закончен, пока отчёт не просмотрен.
7. **Откройте результат** в табличном приложении и сверьте заголовки, порядок строк, формулы и перенесённые значения.

Что смотреть в отчёте

- пустые адреса;
- дубли ключей;
- связи «один ко многим» и «многие к одному»;
- расхождения по дому и корпусу;
- кандидаты с низкой уверенностью;
- строки, не попавшие в результат;
- неожиданное изменение количества строк.

Правила безопасной работы

Сохраняйте исходный порядок строк, если он важен для систем, которые заберут результат дальше.

Не нормализуйте руками часть набора перед автоматическим сравнением: половина приведённых к одному виду строк и половина сырых дают худший результат, чем целиком сырой набор.

Держите исходники и отчёт до приёмки результата.

После изменения логики сопоставления сначала прогоняйте маленький контролируемый набор.

При сбое сохраните журнал и отчёт. Исправьте источник, эталон или разметку колонок — и повторяйте прогон только после того, как поняли причину.